

御网智元

具备自主决策能力的通用网络安全智能体
初审作品说明 | v0.5.0 | 统一工作台 127.0.0.1:8080

证据：正式赛题方案；技术报告；可运行系统

初审回答的问题

复杂任务如何自主规划并动态调整？
如何约束工具、权限与网络边界？
如何让执行过程可解释、可复现、可验证？

证据：赛题评分维度；项目证据矩阵

可审计任务闭环

用户目标 -> 任务快照 -> 规划 -> 受控工具执行 -> 证据沉淀 -> 结果验证 -> 报告。
失败、拒绝和恢复都进入同一条运行轨迹。

不可变 Run 快照

每次运行冻结模型、Agent、授权范围、工具集合、目标和附件摘要。

后续规划与结果始终关联同一 Run，避免配置漂移。

证据：TaskSpec；Run；Artifact；ExecutionStep；Evidence

自主规划与动态调整

默认 Agent 使用 dynamic + verified：先生成任务理解和计划，再执行工具。
遇到工具失败、证据不足或安全拒绝时，系统重规划并保留原因。

工具协同与扩展

ToolSpec 统一输入输出、风险等级、超时和审计契约。
当前覆盖文件、IOC、时间线、编码、哈希、JWT、PCAP、静态分析和授权 localhost HTTP。

证据: ToolSpec; Registry; Executor; 19 个工具契约

附件理解与证据提取

附件先经过类型、大小和归档安全检查，再由受控工具解析。
提取结果作为 Artifact 与 Evidence 保存，不依赖模型口头声称。

本地 Web 只读分析

网络访问限定在用户授权范围，默认仅允许 localhost。
请求、响应摘要和解析结果进入审计轨迹，越界访问被策略层拒绝。

Prompt Injection 防护

外部内容始终按不可信数据处理，不能覆盖系统规则与用户授权。
检测到注入后记录风险并继续完成安全范围内的任务。

证据：提示注入检测；策略拒绝；安全恢复测试

解释、验证与复现

事件流展示每一步决策、工具参数摘要、结果和证据引用。
成功工具调用只代表来源可靠，只有 Evidence/Judge 通过才
显示独立验证。

统一工作台

任务创建、授权、执行进度、工具调用、证据与报告集中在一个界面。
设置和日志均做脱敏处理，默认入口为 127.0.0.1:8080。



证据：真实工作台；Playwright 桌面截图

移动端可用性

移动端保留任务创建、授权确认、运行状态与安全边界入口。
布局针对窄屏重排，核心信息不被裁切或遮挡。



证据：Playwright 移动端截图

工程化与供应链

Docker Compose 一键部署，提供健康检查、迁移、诊断、备份和恢复脚本。

后端、前端、工具契约与依赖审计纳入统一质量门禁。

证据：87.37% 覆盖率；106 项前端测试；Docker 健康检查

通用评测口径

evaluation_cases 提供可扩展的本地评测集合。
每个任务检查结构化结果、成功工具、证据来源、授权范围和预算，不将模型自述当作成绩。

证据：EvaluationRunner；EvaluationScorer；JWT/IOC/编码验收

能力边界与提交

仅处理明确授权的附件和本地目标；不提供任意 Shell，不攻击公网目标，不代替外部平台提交。
决赛平台开放后再适配指定网关和判分协议。