

御网智元 测试与评测报告

日期：2026-08-28

数据口径：仅记录本轮真实命令、持久化状态与文件证据；未运行的真实 Provider 评测明确标为未执行。

1. 环境与自动化检查

环境：Windows、Python 3.11.15、Node.js 26.2.0、Docker Compose v2，服务仅绑定 127.0.0.1。
scripts/full-check.ps1 已通过 Python 测试、Ruff、mypy、前端 lint/typecheck/Vitest/生产构建、生产表面检查、Playwright 4 项 E2E 与 Docker Compose config：298 passed、9 skipped、覆盖率 86.70%。定向回归 26 项通过，覆盖黄金绑定、A 最终工具门槛、C 不补写恢复状态、CSV/ZIP/TAR 资源拒绝和脚本根目录解析。

2. Docker 与部署验收

默认 Compose 已执行 up -d --build，api、web、tool-sandbox 健康；正式 /api/v1/setup/status 在默认环境返回 database/master_key/admin/provider/agent 均为 true。黄金 Compose 在删除其命名卷后通过 compose.yaml + compose.golden-demo.yaml 全新构建，独立卷可创建且服务健康，不依赖预创建 external volume。停止、重启和命名卷持久化已作为本轮验收对象。

3. 依赖审计

生产 npm audit --omit=dev:0 vulnerabilities, 见 evidence/npm-audit-production-20260828.json。
完整 npm audit: 0 vulnerabilities, 见 evidence/npm-audit-full-20260828.json。首次完整审计

发现开发测试链 jsdom 传递 undici@7.28.0 高危项，现仅将 package-lock.json 锁定升级到 undici@7.29.0，未引入生产运行依赖；重跑完整审计为 0。Python 使用 requirements.runtime.lock 与 requirements.lock，pip check 无冲突。

4. 真实 Provider 评测状态

真实评测入口为默认工作台 <http://127.0.0.1:8080/> (2026-08-28, DeepSeek deepseek-v4-flash)；这不是独立黄金 Compose 卷，后者仍未配置 Provider。A 三次真实 Run 为 1 次失败、2 次 8/8 通过，pass@1=0%，前三次至少一次成功率=100%；B 三次均 6/6 通过，pass@1=100%，前三次至少一次成功率=100%。C 首三次为 4/9、4/9、6/9；修复双工具契约及真实工具证据绑定后，后续为 8/9、9/9。最终 9/9 Run 用时 54.248 秒、6 次 Provider 请求、38,056 Token、2 次工具调用、0 次重规划、0 次人工介入。Provider 返回成本为 0.0，不据此推算或宣称免费。默认卷结果不得冒充独立黄金卷验收。

5. 复现与证据索引

1) docker compose -f compose.yaml -f compose.golden-demo.yaml up -d --build；2) 打开 localhost:18080 配置并真实测试 Provider；3) python scripts/init_golden_cases.py；4) A/B/C 各运行三次 scripts/run_golden_demo.py；5) 导出 evaluations/statistics、轨迹和报告；6) docker compose -f compose.yaml -f compose.golden-demo.yaml down。

证据：提交 e6674d5、audit JSON、Playwright 桌面/移动截图、full-check 原始日志、Docker 健康检查、docs/golden-cases/README.md 和 docs/competition-preliminary-review.md。配置阻塞记为“未执行”，不得记为成功或失败。

测试负责人签字：_____ 日期：_____