

御网智元测试与评测报告

质量门禁、通用评测与可复现证据

版本日期：2026-09-03

测试与评测报告

1. 测试口径

本报告只记录可由源码、锁文件、测试输出或 Docker 健康检查复核的事实。真实 Provider 测试在没有隔离密钥时明确跳过，不把 Fake Provider、模型自述或手工截图计作真实成绩。

2. 当前质量门禁

项目	结果
Python 单元/API/安全/评测测试	335 项通过、9 项条件跳过；整体覆盖率 87.37%，高于 85% 门槛
Agent 核心覆盖率门禁	91.72%，高于 CI 的 90% 门槛
Ruff	通过
mypy strict	通过
前端 Vitest	106 项通过
前端 lint/typecheck/build	全部通过
工具契约检查	19 个工具通过
Docker Compose	配置、构建、启动和健康检查通过
Windows doctor	15 项正常、0 警告、0 失败
浏览器验收	任务创建、历史切换、设置和活动流无控制台错误

3. 功能覆盖

- Agent：任务理解、动态计划、动作选择、重规划、暂停/继续、检查点恢复、上下文压缩；
- 工具：文件和归档摘要、Artifact 搜索、IOC、时间线、编码、哈希、JWT、PCAP、字符串、静态分析、localhost HTTP；

- 安全：路径隔离、附件限制、MIME/magic 校验、Prompt Injection 防护、SSRF 边界、凭据脱敏、预算和幂等；
- 结果：Evidence 绑定、TaskResult、独立 Local Judge、报告和 trajectory 导出；
- 评测：本地任务包覆盖 CTF、应急响应、Web、漏洞分析、逆向和失败后重规划。

4. 正式验收案例

当前 acceptance 包包含复杂 IOC、多层编码、多 Artifact 关联、失败后重规划、localhost Web 和 JWT 静态研判。每个案例均检查结构化结果、成功工具、证据来源、授权范围和预算；Judge 配置不进入 Agent 提示。

5. 真实 Provider 评测方式

```
python -m yuwang.evaluation list
```

```
python -m yuwang.evaluation run --case <case-id> --provider-id <UUID> --attempts 3
```

评测统计首次成功率、前三次至少一次成功率、耗时、Token、工具调用、重规划、人工介入和失败分类。没有脱敏原始记录时，不在材料中声称成功率或模型排名。

6. 已知边界

本阶段尚未接入主办方决赛平台、指定安全网关和外部判分协议；没有宣称 Pwn、真实公网渗透或外部 CTFd 提交能力。PCAP 和 JWT 工具是离线静态分析，不执行载荷、不验签、不猜密钥、不重放流量。